



凌运 (/users/150227) 2017-11-16 23:36:05 (最初创作于: 2017-11-16 19:08:08) 发表于: 淘宝搜索算法 (/groups/152)

947 阅读 28 取消收藏 (/articles/94363/unmark)

知识体系: 修改知识体系

文章标签: 算法 (/search?q=算法&type=INSIDE_ARTICLE_TAG) Porsche (/search?q=Porsche&type=INSIDE_ARTICLE_TAG) 修改标签

标签历史 (/articles/94363/tags/history)

附加属性: 内部资料请勿外传 作者原创



Pairwise Learning to Rank with Online Pool Data

问题背景:

此文是 Online Learning to Rank with Neural Network [1] (<https://www.atatech.org/articles/66100>) 的姊妹篇, 是在2016年淘宝主搜场景全量的Ltr算法基础上做的进一步改进。因此强烈建议读者先阅读之前的文章。

在应用上, 本文和[1] (<https://www.atatech.org/articles/66100>)都是主搜高维特征分之间ensemble的方法, 意图通过ltr的方式对我们线上多种排序分数进行融合, 优化实际的线上指标比如gmv, 客单价等。

在实现上, 两者都基于Porsche流式计算平台训练, 秒级训练, 分钟级投放生效, 能够很好地适配大促等排序场景。

改进点详解:

训练样本选择: one-pass -> pool:

为何提出新的样本使用方式

之前的[1] (<https://www.atatech.org/articles/66100>)一个非常明显的特点就是所有的数据只用一遍, 成交样本会把大权重分成多个小权重的样本进行训练, 所有分裂后的小权重样本都只用一次。

分析one-pass的优缺点:

one-pass优点

1. 由于样本只用一次, 几乎没有过拟合的担忧
2. 对于线上数据响应非常及时

one-pass缺点

1. one-pass learning无法使用之前发生的历史样本, 因此其受到线上样本qps的严重限制, 当模型复杂或者qps较少时, 收敛慢且效果容易不稳定。
2. 相比传统的离线算法可以在离线数据上进行训练迭代至收敛, one-pass的方式很难说明它已经收敛了, 也难以用传统的离线指标去对比不同方法的好坏, 对于模型的日后改进不利。

改进one-pass方法

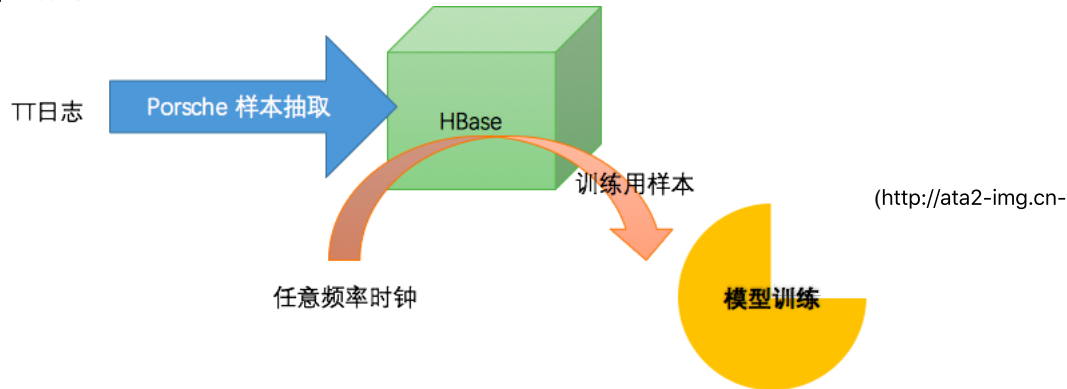
综合以上思考, 我们提出pool learning的方式, 即类似于强化学习中的replay buffer, 两者的大致流程图如下:

one-pass方式



<http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/ee53d938c762b98e46fa7ffd3d26f5ca.png>

pool方式



hangzhou.img-pub.aliyun-inc.com/f8c7ef278e321bddf43cd793cea7b3be.png)

- 构建pool: 每隔5分钟的时间, 我们建立一个pool, 将5分钟内的数据随机插入其中 (大权重的成交样本被拆分成多条小权重的样本插入pool中)
- 使用pool: 我们设置训练样本距离当前时间最大允许的时间间隔 (比如最近2小时的数据), 然后随机取时间间隔中某个5分钟的pool中的某条随机样本出来进行训练。

pool方法特点:

改进one-pass缺点:

- 通过将样本的保存和使用分开, 我们可以自定义合适的足够大的qps使用数据, 使训练过程快速收敛。
- 在离线对比时, 我们也可以构建5分钟的pool, 使用n个小时的样本进行训练, 把训练pool之后的样本作为预测集进行模型的调优。

相比one-pass原有优点:

- 通过离线的超参数的设置, 我们可以防止线上训练过拟合的发生
- 最近n个小时的数据的n是可以灵活调整的, 在大促场景用户行为较为活跃时, 我们可以将时间窗口缩短, 以增大模型响应速度; 而在平时可以设的稍大以增强模型稳定性。

Objective选择: pointwise -> pairwise

为何选择新的Objective

在排序优化的过程中, 我们对某个特征分进行优化后, 配以固定的权重, 其在线上整体的排序效果优于将该特征分放入之前的[1] (<https://www.atatech.org/articles/66100>)中学得的效果。产生如此结果的原因也很容易解释, ltr的目标和真实的指标之间的gap阻碍了排序效果的进一步提升。为此我们探索了其他多种优化目标, 并最后采用带权重的pairwise的方式进行学习。

候选Objective

- 对于pointwise的目标, 形如在[1] (<https://www.atatech.org/articles/66100>)中, 我们采用了带权重的pointwise的learning to rank方法进行优化。其最小化的目标函数如下

$$Loss(\mathbf{w}) = \sum_i n_i \log(1 + \exp(-y_i \mathbf{w}(\mathbf{s})^T \mathbf{x}_i))$$

其中 $\mathbf{x}_i \in \mathbb{R}^m$ 是每个排序中商品的特征分, $\mathbf{w} \in \mathbb{R}^m$ 是所学的特征分的权重 $y_i \in \{-1, +1\}$ 是正负样本的label, $n_i \in \mathbb{R}$ 是不同样本根据来源例如点击、成交不同而带的不同权重。 $\mathbf{s} \in \mathbb{R}^k$ 是跟query、用户特性相关的向量; $\mathbf{w}(\mathbf{s})$ 是 $\mathbb{R}^k \rightarrow \mathbb{R}^m$ 的函数, 以期使得不同的query和用户拥有不同的排序权重。其中定义

$$f_{\theta}(\mathbf{x}, \mathbf{s}) = \mathbf{w}(\mathbf{s})^T \mathbf{x}$$

为我们对每个商品的打分函数, 受限于去年的引擎实现, ensemble时我们仅能用线性的方式对 \mathbf{x} 进行打分, 其模型参数为 θ 。一般用以评判其训练结果好坏的是样本的带权AUC指标。

- 对于Pairwise目标, 其最小化的目标函数如下

$$Loss = \sum_{i,j} n_{i,j} \log(1 + \exp(-y_{i,j} (f_{\theta}(\mathbf{x}_i, \mathbf{s}_i) - f_{\theta}(\mathbf{x}_j, \mathbf{s}_j))))$$

其中 $y_{i,j} \in \{-1, +1\}$, 当 \mathbf{x}_i 优于 \mathbf{x}_j 时取+1, 否则取-1 其优化的是同一个展现(PV)下样本的AUC, 并在不同PV下取平均 (以下简称PVAUC指标), 在pair选择上即 i, j 的选择, 我们也尝试了 3种方法:

- 有成交的PV内的所有非成交样本与成交样本组成pair
- 有成交PV内的成交样本周围的样本与成交样本组成pair
- 有成交PV的用户名及query相同的所有PV内的非成交样本与成交样本组成pair 对于手淘主搜场景, 一个PV大概可以展现约10个宝贝。

3. 之后，为了兼顾AUC和PVAUC指标，我们可以对pair内的正负样本采用相同大小的权重，兼顾2个指标，产生一种折中的优化目标如下

$$Loss = \sum_{i,j} n_{i,j} (\log(1 + \exp(-y_i f_{\theta}(\mathbf{x}_i, \mathbf{s}_i))) + \log(1 + \exp(-y_j f_{\theta}(\mathbf{x}_j, \mathbf{s}_j))))$$

其优化的AUC和PVAUC均介于前2种方法之间。

确定 $n_{i,j}$

在Pairwise的loss中，我们需要某一对pair的 $n_{i,j}$ ，参考Pointwise[1] (<https://www.atatech.org/articles/66100>)我们调整样本权重的方式，我们得到成交样本 \mathbf{x}_i 的权重 n_i 并设定 $n_{i,j} = n_i$ for all j 同样可以起到gmV或者客单价的目的。



小结：

通过实际线上测试效果，我们最终选择PVAUC作为我们优化的目标，且抽取pair的方式为第一种方案：有成交PV内的所有非成交样本与成交样本组成pair。在实验过程中，新加入某个特征之后，原有的pointwise方法无法继续有效地提升gmV了，PVAUC的方法则可以继续提升约2%的gmV，能够和人工设定固定的权重的结果相持平。

模型选择： Linear Ranker -> DnnRanker + Linear Ranker

在[1] (<https://www.atatech.org/articles/66100>)中，由于当时的引擎实现局限性， $f_{\theta}(\mathbf{x}, \mathbf{s}) = \mathbf{w}(\mathbf{s})^T \mathbf{x}$ 的形式对商品的高维特征分 \mathbf{x} 进行线性组合，进行ensemble。今年，在引擎的升级中，我们得以实现使用可实时更新权重的神经网络模型来重新实现 $f_{\theta}(\mathbf{x}, \mathbf{s}) = nn_{\theta}(\mathbf{x}, \mathbf{s})$ 。

考虑到线上ensemble模型的可解释性，我们又在最后将DnnRanker的产出与其他分数进行线性组合。

$$f_{\theta_1, \theta_2}(\mathbf{x}, \mathbf{s}) = \mathbf{w}_{\theta_2}(\mathbf{s})^T \begin{bmatrix} \mathbf{x} \\ nn_{\theta_1}(\mathbf{x}, \mathbf{s}) \end{bmatrix}$$

观察 $\mathbf{w}_{\theta_2}(\mathbf{s})$ 的权重，可以发现， $nn_{\theta_1}(\mathbf{x}, \mathbf{s})$ 对应的权重占了超过一半。因为 $nn_{\theta_1}(\mathbf{x}, \mathbf{s})$ 的目标和训练 f_{θ_1, θ_2} 一致，因此符合预期。

正则化：超参数的选择不是全部

选定训练样本，确定优化目标和模型结构之后，我们需要对模型进行优化，其中免不了对于模型训练的正则化。由于训练的pool总时间窗口太大会丧失实时性的特点，我们选择的pool一般不会超过4个小时，能够搜集到的成交样本也有限，离线训练就可以很明显发现过拟合的现象。通过常用的正则化方式，我们可以得到一个较为稳定的超参数版本，想着要把它送到线上，但是这还不是全部。

实时训练过程中，由于线上流量的差异，虽然同样是n个小时的样本，凌晨和晚高峰的qps其实相差甚远，因此我们在选择好正则化的超参数之后，还要监控实际的每一层网络权重的norm大小以确保正则化生效是合理的。

此外，在实际实验中，我们发现对于输入的 \mathbf{x} 加入高斯的扰动可以增强模型的鲁棒性。

双十一实验结果

在双十一当天，结合新加入的其他特征分扩展 \mathbf{x} 后，顶层采用 $f_{\theta_1, \theta_2}(\mathbf{x}, \mathbf{s})$ 的形式，以pairwise的loss训练，相比去年的[1] (<https://www.atatech.org/articles/66100>)版本，gmV获得了约12%的提升，为全网多带来了约15亿的增量成交额！

总结与守望

过去的一年里，通过不断地尝试和探索，守望着一夜一夜的报表，经历了一次又一次的碰壁，终于在去年[1] (<https://www.atatech.org/articles/66100>)的基础上又进步了一点。未来主搜场景下Ltr相关的挑战也会越来越难。其中寻找到合适的objective来缩小我们的优化loss和真实线上指标的gap一直是我们在做的一件事情。

上文没有提到的一种类似于广告的 $ctr * price$ 的目标的方式我们类似地尝试过 $cvr_{pv-pay} * price$ 。但是仅依赖于现有的高维特征分 \mathbf{x} 也会出现很多的badcase，指标也很难看。也许是cvr估计的不够准确吧，也许是用于Ensemble的高维特征分训练的目标由于搜索长远的历史原因，侧重点不同吧。

未来：

1. 还是需要继续探索 $cvr_{pv-pay} * price$ 为目标来优化gmV时的方向，加入更多底层的特征，不仅仅依赖高维特征分的ensemble。
2. 也许上文提到的Pairwise Loss目标更适合我们的问题，因此同样需要融入更多底层的特征分进行尝试训练，得到更强的模型。

最后特别感谢搜索工程团队悟时、彻空、远石、亦烟、风夏、以琛、夕肆、澄空、奥萨等同学的帮助，为算法的成功上线创造了可能。

[1] Online Learning to Rank with Neural Network <https://www.atatech.org/articles/66100>
(<https://www.atatech.org/articles/66100>)

评论文章 (6)  59 (</articles/94363/voteup>)  0 

他们赞过该文章



飘雪 (</users/5036>) 三桐 (</users/5262>) 青峰 (</users/5993>) 喜德 (</users/6818>) 仁重 (</users/7553>) 天铎 (</users/8102>) 项梁 (</users/8109>)
元涵 (</users/8200>) 萱然 (</users/8818>) 盛和 (</users/13857>) 苏哲 (</users/14317>) 浩南 (</users/14690>) 肖荣 (</users/15130>)
赤松 (</users/15896>) 晨松 (</users/16076>) 墨青 (</users/16140>) 务达 (</users/18103>) 帛逸 (</users/19201>) 微宏 (</users/19248>)
一尘 (</users/19779>) 清灵 (</users/19943>) 海凯 (</users/20097>) 仁基 (</users/24830>) 龙楚 (</users/35298>) 开锋 (</users/64794>)
影生 (</users/66008>) 辽玥 (</users/66808>) 乘月 (</users/66827>) 藤木 (</users/67095>) 京五 (</users/69176>) 天栋 (</users/74464>)
瑞溪 (</users/75598>) 穹武 (</users/75723>) 向寒 (</users/81643>) 问长 (</users/92055>) 名然 (</users/98030>) 九谦 (</users/106121>)
米源 (</users/114800>) 润墨 (</users/126303>) 伽佑 (</users/130099>) 谷仁 (</users/150208>) 亦汀 (</users/150544>) 劲恣 (</users/151517>)
哲予 (</users/190136>) 湛渊 (</users/197505>) 江扬 (</users/208431>) 逆竹 (</users/210536>) 撒夫 (</users/222653>) 宇淮 (</users/226622>)
坚行 (</users/236456>) 素数 (</users/240804>) 由拳 (</users/267317>) 征辰 (</users/277343>) 凯远 (</users/326116>) 濫川 (</users/333844>)
喜阅 (</users/352088>) 极泓 (</users/358491>) 有痕 (</users/413678>) 茂叶 (</users/424798>)

相似文章

- 基于实时Stream的推荐算法及并行架构 (</articles/43759>)
- 搜索双链路实时计算体系@双11实战 (</articles/44909>)
- 在线学习算法 OnePassAUC 的实践之路 (</articles/53867>)
- 基于强化学习的手淘推荐全链路优化 (</articles/67234>)
- 淘宝展示广告中的OCPC智能调价技术 (</articles/74316>)
- 直通车预算约束下的 pacing 优化技术 (</articles/89234>)

上一篇：Online Learning to Rank with Neural Network (</ar...>)

- 1F

[一尘 \(</users/19779>\)](/users/19779)

赞dnn -ltr 首席工程师！

赤松 赞同

 1 (</comments/150905/voteup>)  0

2017-11-16 19:21:40
- 2F

[元涵 \(</users/8200>\)](/users/8200)

赞，今年尝试了各种方法，各种碰壁，终于又前进了一步。没想到去年自己上线的版本这么强大吧，明年将面对一个更强大的baseline

坚行、浩南、凌运 赞同

 3 (</comments/150947/voteup>)  0

2017-11-16 21:41:41
- 3F

[清灵 \(</users/19943>\)](/users/19943)

ltr科学家

 0 (</comments/150981/voteup>)  0

2017-11-17 09:35:26
- 4F

[问长 \(</users/92055>\)](/users/92055)

厉害了凌云老师

 0 (</comments/151001/voteup>)  0

2017-11-17 09:59:32
- 5F

[瑞溪 \(</users/75598>\)](/users/75598)

将ltr发挥到极致

 0 (</comments/151022/voteup>)  0

2017-11-17 10:17:17
- 6F

[协明 \(</users/67100>\)](/users/67100)

牛逼 666

 0 (</comments/151267/voteup>)  0

2017-11-17 16:18:56

写下你的评论... 



评论

