



葬青 (/users/102276) 2017-04-05 19:03:54 (最初创作于: 2017-03-24 21:43:33)

330 阅读

知识体系: 修改知识体系

文章标签: 算法 (/search?q=算法&type=INSIDE_ARTICLE_TAG) 推荐算法 (/search?q=推荐算法&type=INSIDE_ARTICLE_TAG) 个性化推荐 (/search?q=个性化推荐&type=INSIDE_ARTICLE_TAG) 推荐 (/search?q=推荐&type=INSIDE_ARTICLE_TAG) 推荐系统 (/search?q=推荐系统&type=INSIDE_ARTICLE_TAG) 个性化 (/search?q=个性化&type=INSIDE_ARTICLE_TAG) 多样性 (/search?q=多样性&type=INSIDE_ARTICLE_TAG) 新颖性 (/search?q=新颖性&type=INSIDE_ARTICLE_TAG) 惊喜性 (/search?q=惊喜性&type=INSIDE_ARTICLE_TAG) 多样性推荐 (/search?q=多样性推荐&type=INSIDE_ARTICLE_TAG)
 修改标签 标签历史 (/articles/75902/tags/history)



附加属性: 内部资料请勿外传 作者原创

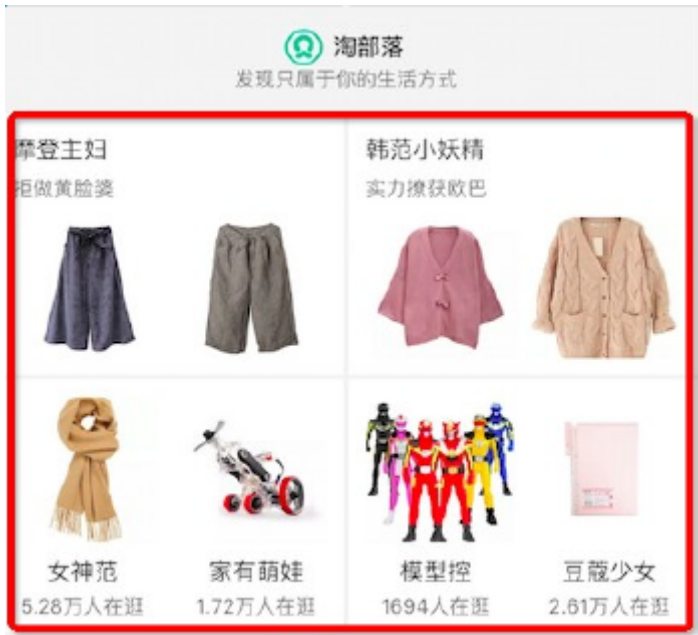
基于Wundt曲线的惊喜性推荐

华仔、凌点、葬青

业务背景

惊喜性推荐一直是个性化推荐的一个重要衡量目标，而且随着整个手淘个性化元年的到来，手淘首页各个模块都开始进行了各种各样的实时个性化推荐,往往你点击或者收藏或者加购了一件物品，整个手淘页面都是类似的商品。但是对于算法的衡量目标-点击率来说，粗暴的进行各种曝光过滤以及类目打散会道正点击率下降厉害，指标难看。本文就是要解决在保证点击率不降的基础上尽可能的扩大惊喜性带来的收益，让用户在发现中得到惊喜的商品，不在全屏一种商品所困扰。

本文的实验场景位于手淘首页生活研究所，如下图所示：



(<http://ata2-img.cn-hangzhou.img->




pub.aliyun-inc.com/726af0fbf124a7cd2932b559c2c657c6.png

需要在保证高点击率的情况下，尽可能的保证人群、类目、宝贝的多样性，提高用户的"小惊喜"。

Wundt曲线

Wundt曲线被誉为心理学第一第一定律，它向人们揭示了一个这样的心理学现象：人们对于过于新奇或者陈旧的信息都不会产生良好的心理学反应，如愉快、兴奋等。这种愉快、兴奋感伴随着事物的新奇性增加呈现倒U型曲线。具体曲线形式如下：




([http://ata2-img.cn-hangzhou.img-pub.aliyun-](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/7708ca9d79e344c0e9b6d6903e7890fe.png)

图 1 Wundt 曲线

[inc.com/7708ca9d79e344c0e9b6d6903e7890fe.png](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/7708ca9d79e344c0e9b6d6903e7890fe.png))

对于上面图中的曲线，横坐标表示外界的刺激，总坐标表示用户的愉悦感，可以很明显的看到曲线的变化如上所示。用户在一个可接受的刺激范围内，随着外界刺激的增大,用户的愉悦感增大，但是一旦超过用户的可接受的范围上限，用户的愉悦感随之消失，甚至厌恶。给用户进行个性化的多样性推荐也有类似的效果，当你给用户推荐的商品的惊喜性在一个用户可以接受的范围内，用户很乐意接受这种惊喜，但是一旦超过了用户的极限，那么用户会很厌恶。参考Wundt曲线，在推荐过程用户对惊喜的表现也如下图所示：



([http://ata2-img.cn-hangzhou.img-pub.aliyun-](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/45e609e12ba998d01d5092e15d1e62a0.png)
[inc.com/45e609e12ba998d01d5092e15d1e62a0.png](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/45e609e12ba998d01d5092e15d1e62a0.png))

一个宝贝对用户的惊喜性可以看做一个刺激，一开始这个刺激如果在一个合理的范围内，用户的惊喜性被它激发的兴趣越来越高，一旦超过了一个阈值高点，那么用户的这种惊喜被打破，转而化为延误。

量化惊喜性

整个业界对惊喜性的定义各有自己的方法，为了更加切合我们的场景，衡量整个场景的惊喜性指标，我们对惊喜性的指标进行如下定义：

$$Novelty = \sum_{u \in S} \frac{1}{|S| |H_u|} \sum_{h \in H_u} \sum_{i \in R_{u,h}} \frac{1 - sim(i, h)}{8}$$



(<http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/aabe6342fd452e2f1b968bb8564c2e56.png>)

用户进入手淘页面，在各个场景的行为无时无刻不反映出用户对惊喜性的需求，时而追求惊喜性时而追求找相似。一个宝贝对用户的惊喜影响也是多方面的，为了简化问题，定义宝贝*i*在*t*时刻对用户*u*的惊喜性如下：

$$Novelty_{u-i}^t = \frac{1}{3} * (SF_{u-i}^t + SR_{u-i}^t + Dim_{u-i}^t) \quad (\text{http://ata2-img.cn-}$$

[hangzhou.img-pub.aliyun-inc.com/518a321a6853c86ae88412a6d0f4910e.png](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/518a321a6853c86ae88412a6d0f4910e.png))

对于括号中的SF表示用户对宝贝属性（本身\类目）的操作频次与惊喜性成反比关系，SR表示用户对宝贝属性(本身/类目)的操作时间与当前时间的远近成反比关系，Dim表示用户对宝贝的标签操作频次与时间操作成反比关系，三个变量的具体定义如下：

$$SF_{u,i}^t = \frac{e^{-\rho_a \cdot |A_{u,i}^t|} + e^{-\rho_i \cdot |I_{u,i}^t|}}{2} \quad (\text{http://ata2-img.cn-}$$

[hangzhou.img-pub.aliyun-inc.com/2acd132f63be07c0542d9cf99f6c5851.png](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/2acd132f63be07c0542d9cf99f6c5851.png))

对于分子的第一项表示用户*u*对宝贝*i*所在类目的操作频次，第二项表示用户*u*对宝贝*i*的重复操作行为频次。

$$SR_{u,i}^t = \frac{e^{\rho_t \cdot (t - t(A_{u,i}^{-1}))} + e^{\rho_t \cdot (t - t(I_{u,i}^{-1}))}}{2} \quad (\text{http://ata2-img.cn-}$$

[hangzhou.img-pub.aliyun-inc.com/2ccdf0bc11a2f0aca5daabd9bb5baaa4.png](http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/2ccdf0bc11a2f0aca5daabd9bb5baaa4.png))

分子的第一项表示用户*u*对宝贝*i*的类目的操作时间间隔,第二项表示用户*u*对宝贝*i*的行为时间间隔

$$Dissim_{u,i}^t = \frac{1}{|2 \cdot Tags(i)|} \sum_{tag \in Tags(i)} (e^{-\rho_{tag} \cdot |I_{u,tag}|} + e^{\rho_t \cdot (t - t(I_{u,tag}^{-1}))}) \quad \uparrow$$

(<http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/99c22d68bdc1f7de149fe3f3e1fb0b39.png>)

分子的第一项表示用户u对宝贝i的tag的操作频次,第二项表示用户u对宝贝i的tag的操作时间间隔

算法框架


算法的框架是从离线和在线两个方面来进行探索满足用户在进入手淘页面的时候的对惊喜性的需求，从长期来说，考虑一个用户是否是一个善于发现“惊喜”的用户，如果面对这样的用户需要怎么进行推荐？从短期实时来说，用户的惊喜性需求是一个动态的过程，在上一时刻用户找相似的需求强烈，在下一个时刻用户可能厌倦了找相似转而对惊喜性进行更高的要求。

基于上述两种假设我们从离线U2I和在线实时决策两个方面进行了算法探索与实验。

基于长期用户惊喜行为的U2I

U2I反应的是用户维度对宝贝的热爱程度，结合用户对宝贝的惊喜性需求，对U2I宝贝进行重排序，具体过程如下：

- 对用户的全网点击的数据进行统计，以天为单位计算用户对每个宝贝的惊喜性
- 基于第一步产出的用户宝贝惊喜性序列，对其进行建模仿真，通过统计大体可以看到长期来说，用户的惊喜性分布服从Beta分布，通过拟合用户的惊喜性分布，得到Beta分布的超参数，具体如下：



(<http://ata2-img.cn-hangzhou.img->

pub.aliyun-inc.com/6949efb6582b94f0cecc1895b786d678.png)

- 基于用户惊喜性分布的Beta分布对于外界刺激预估 对于上述算法中产出的用户长期惊喜性Beta分布的用途主要从以下两个方向进行：
- 对于U2I候选的宝贝每一个宝贝利用预估的Beta分布进行惊喜性打分，离线融合U2I的偏好分和惊喜性分排序

$$MatchScore = a * preferScore + (1 - a) * SeverityScore$$

(<http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/d2574727a6645278d4880ed5b425daa1.png>)

- 拟合出用户的长期惊喜性分布的Beta分布可以找出用户能忍受的最大刺激值。众所周知，现在很多的推荐场景都有随机的过程，随机的过程就是一种暴力的全局惊喜性方案，在这里，利用这个最大的刺激值（0~1）对用户线上进行个性化的随机，比如原先的暴力随机的用法如下：

$$MatchScore = f(MathScore, RandomScore)$$
 (http://ata2-img.cn-

hangzhou.img-pub.aliyun-inc.com/b5fee705d048188bb07ddeeb736e0538.png)

现在基于用户的长期惊喜性最大刺激值，可以进行如下的随机方案：

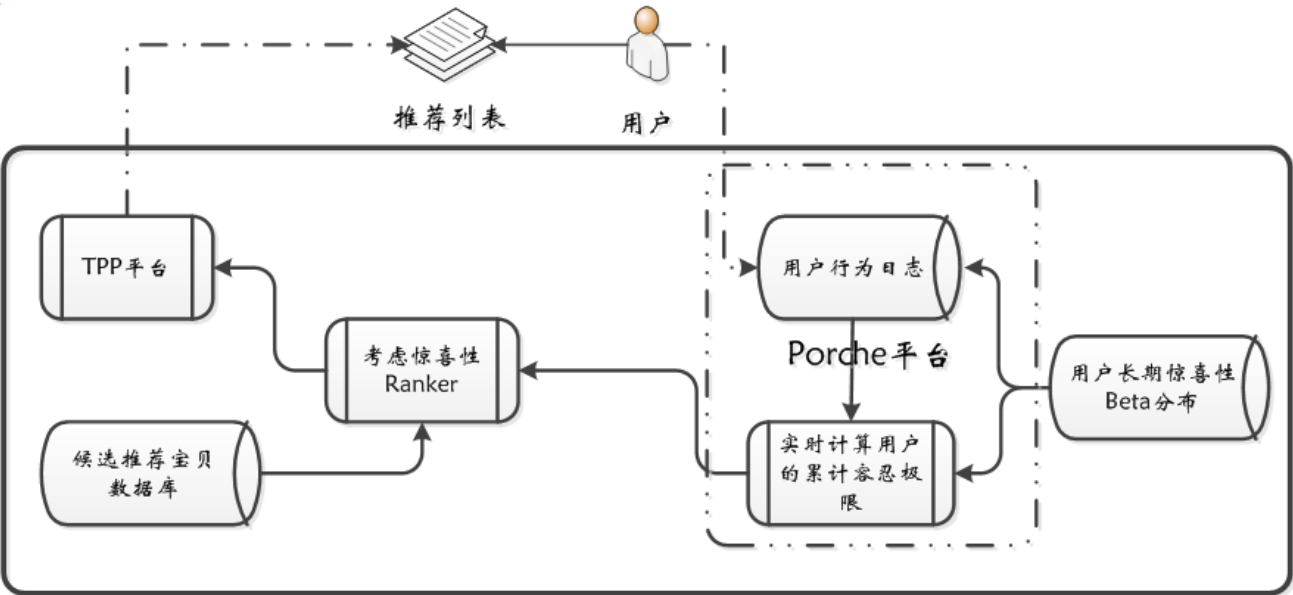
$$MatchScore = f(MathScore, Min(RandomScore, USeverityDivesity))$$

(http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/df98f369306e765250ef5812358ed10e.png)

基于实时累计用户惊喜性推荐



在实际的场景下，用户对惊喜性的需求并不是一成不变的或者一天一变的，而是随时可能发生变化，在前一个时刻用户在积极的找相似，下一个紧邻的时刻用户就突然对惊喜性需求大增。为了在推荐的过程中，使得对用户的惊喜性推荐始终处于一个令用户“愉悦”的刺激区间内，需要在线模拟用户接受刺激的反应过程。具体设计框架如下：



(http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/4d433bc9482e5482ca47136d4411d7ab.png)

如上图所示，结合实时特征平台Porche，设计了如上的整套实时对用户进行惊喜性追踪和推荐。

目前离线U2I策略已经上线，UV点击率在原来的基础上略有提升，同时惊喜性指标也比原来提升很大，具体见如下：

Novelty	2017022609	2017022610	2017022611	2017022612	2017022613
基准桶 (UserCat Ctr GBDT)	0.016157833	0.016093098	0.01563388	0.015616456	0.015955382
对比桶 (Curious Model&UserCat GBDT)	0.016339714	0.016163932	0.015828159	0.015784148	0.016094682
变化	1.13%	0.44%	1.24%	1.07%	0.87%
平均提升	0.95%				

(http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/44a53ffa8c694f88fe8704e1d2abb0bc.png)



uctr	2017022609	2017022610	2017022611	2017022612	2017022613
基准桶 (UserCat Ctr GBDT)	0.099874531	0.100515222	0.099431425	0.099584485	0.102401798
对比桶 (Curious Model&UserCat GBDT)	0.100972478	0.100737536	0.099978726	0.100432403	0.103010427
变化	1.10%	0.22%	0.55%	0.85%	0.59%
平均提升	0.66%				

(<http://ata2-img.cn-hangzhou.img-pub.aliyun-inc.com/648057d98a322fbf5be674dfc0eab957.png>)

参考资料



- 1、Wundt曲线
(<http://www.ixueshu.com/document/2d1730a984243ab4318947a18e7f9386.html>)
- 2、用户的个性化推荐KDD ()

评论文章 (1)

6 (/articles/75902/voteup)

0

15 取消收藏 (/articles/75902/unmark)

他们赞过该文章

欧拉 (/users/20860) 昔班 (/users/60065) 鹿鹤 (/users/106598) 乐檬 (/users/128525)
弘轶 (/users/134084) 灵盼 (/users/367624)

相似文章

- 个性化推荐在策略与UI上的一点改进尝试 (/articles/1095)
 - Look-alike模型在线系统 (/articles/13710)
 - 搜索广告质量分：从单维度到多维度 (/articles/15993)
- 搜索广告个性化初探 (/articles/13668)
 - LBS实时推荐初探 (/articles/14025)
 - 微淘首页瀑布流优化 (/articles/55347)

上一篇：深度学习在个性化推荐点击率预估... 下一篇：九层之台,起于垒土--记2017飞猪个...

1F 淘龔 (/users/125002) 2017-03-25 00:56:27


厉害

0 (/comments/124846/voteup) | 0

写下你的评论...



评论

© 2018 阿里巴巴集团 版权所有 Copyright© 18 ATA. All rights reserved. 
(http://www.cnzz.com/stat/website.php?web_id=1254194462)

[ATA社区常见问题汇总 \(/articles/67826\)](/articles/67826)

